

作业感受

(1) 简述下你是如何完成第一次挑战的：

- 在 wsl 上初步分隔开环境后，通过 ai 对环境安装及初次运行中存在的部分依赖版本的兼容问题先进行处理解决，然后逐步执行推理和 mooncake trace 采样的任务，过程中主要重复 执行任务 - 报错 - ai 分析日志 - 按建议执行操作 - 回滚或进入下一阶段 的流程，直到两个任务均成功完成。
- 后续的理论机制与流程的问题，主要通过询问 ai 并梳理体系，进而增进我个人对问题中各项机制流程的理解，然后按个人理解独立撰写回答文档。

(2) 你觉得哪部分工作最困难，你是如何克服这个困难的：

- 个人认为 Mooncake trace 采样 workload 的工作最困难。由于对推理引擎底层接触较少，初次接触 Mooncake trace 采样相关的概念难以理解，且网上相关描述较少，只能通过不断重复询问 ai 相关知识来初步加深理解，初步理解概念与相关指令后能够执行 获取 Mooncake trace - 采样部分记录 - 使用 ai 编写的脚本将 workload 发送至 sglang 推理 的流程，最终成功完成任务。

(3) 你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的 科研工作有什么启发：

- 1.明确问题与需要，比如 SGLang 通过各种机制来达到提高性能的目的。
- 2.技术及其环境的可复现，防止因技术环境迭代导致的兼容问题。
- 3.数据负载的研究与设计，比如像 Mooncake trace 采样 workload 得到可控的性能指标的设计。
- 4.可迭代的工作方案，科研肯定不是一次性就能成功，需要有明确的迭代工作流程来解决问题，改进工作。

- 启发：失败报错是很常见的问题，只要记录分析后解决，获得的解决方案也是有价值的，只要从中学到了东西就是成功的。同理，当一个路径行不通时，尝试其他方案解决，不能停留在一处，科研需要灵活的思维来扩宽思路。